ЛАБОРАТОРНАЯ РАБОТА № 1

ОБУЧЕНИЕ ПОЛНОСВЯЗНЫХ НЕЙРОННЫХ СЕТЕЙ: КЛАССИФИКАТОРЫ И РЕГРЕССОР

1. Цель работы

Получить практические навыки подготовки табличных данных, построения, обучения и оценки полносвязных нейронных сетей прямого распространения (MLP) для решения задач бинарной классификации, многоклассовой классификации и регрессии.

2. Задачи работы

- загрузить и исследовать назначенный набор данных; определить целевой признак, типы признаков, пропуски, выбросы и распределение целевой переменной;
- выполнить предварительную обработку данных и разделить выборку на обучающую, валидационную и тестовую части;
- разработать и обучить не менее трёх вариантов архитектуры MLP для каждой из трёх задач;
- исследовать влияние числа скрытых слоёв, количества нейронов, функций активации, оптимизатора и параметров обучения;
- оценить модели с помощью установленных метрик, сравнить их с базовыми моделями и проверить наличие переобучения;
- выбрать лучшую модель для каждой задачи и обосновать выбор на основании результатов на валидационной и тестовой выборках.

3. Индивидуальные варианты и наборы данных

Вариант определяется преподавателем: при нечётной цифре используется набор данных из первой строки вариантов, при чётной — из второй. Каждый студент решает все три задачи: бинарную классификацию, многоклассовую классификацию и регрессию.

Последняя цифра дня рождения	**Задача**	**Набор данных и целевой признак**
Нечётная	Бинарная классификация	Diabetes Health Indicators Dataset (Kaggle). Целевой признак: Diabetes_012. Сформировать бинарную метку: 0 — нет диабета; 1 — преддиабет или диабет (исходные значения 1 и 2 объединить).
Нечётная	Многоклассовая классификация	Body Performance Data (Kaggle). Целевой признак: class. Предсказывать исходный класс физического развития.
Нечётная	Регрессия	Wine Quality, файл winequality-white.csv (UCI). Целевой признак: quality.
Чётная	Бинарная классификация	Bank Marketing (UCI). Целевой признак: y — факт подписки клиента на срочный депозит (yes/no).
Чётная	Многоклассовая классификация	Fetal Health Classification (Kaggle). Целевой признак: fetal_health (три класса состояния плода).
Чётная	Регрессия	Bike Sharing Dataset (UCI), файл day.csv. Целевой признак: cnt — общее количество аренд велосипедов за день. Не использовать casual и registered как входные признаки, поскольку cnt является их суммой.

Ссылки на наборы данных:

- Diabetes Health Indicators: https://www.kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset

- Body Performance: https://www.kaggle.com/datasets/kukuroo3/body-performance-data
- Wine Quality: https://archive.ics.uci.edu/dataset/186/wine+quality
- Bank Marketing: https://archive.ics.uci.edu/dataset/222/bank+marketing
- Fetal Health Classification: https://www.kaggle.com/datasets/andrewmvd/fetal-health-classification
- Bike Sharing: https://archive.ics.uci.edu/dataset/275/bike+sharing+dataset

4. Требования к подготовке данных

- Провести первичный анализ: размер набора данных, типы столбцов, целевой признак, число и доли классов (для классификации), описательная статистика (для регрессии), пропущенные значения и дубликаты.
- Исключить из входных признаков идентификаторы и признаки, прямо или косвенно раскрывающие целевую переменную (утечка целевой информации). Для Bike Sharing не включать casual и registered при прогнозировании cnt.
- Категориальные признаки преобразовать в числовой вид (например, One-Hot Encoding). Числовые признаки масштабировать (например, StandardScaler или MinMaxScaler).
- Пропуски обработать способом, обоснованным характером данных (например, заполнение медианой для числовых и наиболее частым значением для категориальных признаков).
- Сначала разделить данные на обучающую, валидационную и тестовую части. Рекомендуемое соотношение — 70% / 15% / 15%. Для классификации применять стратифицированное разбиение, если это возможно.
- Параметры предобработки (импутацию, кодирование, масштабирование) обучать только на обучающей части, затем применять без повторного обучения к валидационной и тестовой частям. Это предотвращает утечку данных.
- Для воспроизводимости зафиксировать random_state/seed. В отчёте указать способ разбиения и размеры полученных выборок.

5. Построение и обучение моделей

Для каждой задачи необходимо исследовать не менее трёх архитектур полносвязной нейронной сети. Архитектуры должны различаться хотя бы одним существенным параметром.

Параметр	Что необходимо исследовать
Архитектура	Число скрытых слоёв и количество нейронов (например, компактная, средняя и более глубокая/широкая конфигурации).
Функции активации	Например, ReLU; при необходимости — tanh или другие обоснованные варианты. В выходном слое классификатора использовать sigmoid (бинарная задача) или softmax (многоклассовая задача); для регрессии — линейный выход.
Оптимизатор	Например, Adam и один альтернативный оптимизатор (RMSprop или SGD).
Регуляризация	Исследовать хотя бы один способ снижения переобучения: Dropout, L2-регуляризацию или Early Stopping.
Обучение	Указать loss-функцию, batch_size, число эпох, learning rate и критерий остановки.

Рекомендуемые функции потерь: бинарная кросс-энтропия (Binary Crossentropy) для бинарной классификации; категориальная или разреженная категориальная кросс-энтропия (Categorical/Sparse Categorical Crossentropy) для многоклассовой классификации; MSE (Mean Squared Error) для регрессии.

Для несбалансированных классов оценить распределение меток и при необходимости использовать class_weight, взвешивание функции потерь или другие обоснованные методы. Не применять балансировку к тестовой выборке.

Выбор архитектуры и гиперпараметров выполнять по результатам на валидационной выборке. Тестовую выборку использовать для итоговой независимой оценки выбранной модели; не подбирать по ней гиперпараметры.

6. Метрики качества и критерии интерпретации

6.1. Бинарная классификация

Для каждой исследованной модели вычислить на тестовой выборке следующие показатели:

Метрика	Смысл	Ориентир для интерпретации
Recall (полнота)	Доля правильно найденных объектов положительного класса среди всех фактически положительных объектов.	Желательно ≥ 0,80; особенно важна при высокой цене пропуска положительного класса.
Precision (точность положительного прогноза)	Доля правильных положительных прогнозов среди всех прогнозов положительного класса.	Желательно ≥ 0,80; особенно важна при высокой цене ложного срабатывания.
Balanced Accuracy (сбалансированная точность)	Среднее арифметическое полноты по двум классам: $(\text{Recall}_0 + \text{Recall}_1) / 2$.	Желательно ≥ 0,80. Учитывает качество распознавания обоих классов.
ROC-AUC	Площадь под ROC-кривой; характеризует способность модели ранжировать положительные объекты выше отрицательных.	Желательно ≥ 0,80; 0,5 соответствует уровню случайного ранжирования.

Примечание. В предыдущей редакции задания использовалось название Weighted Accuracy. Чтобы исключить неоднозначность, в этой редакции применяется термин Balanced Accuracy (сбалансированная точность) с приведённой выше формулой. Обычная Accuracy и взвешенная по support средняя метрика не являются тем же самым показателем.

Для бинарной классификации дополнительно построить матрицу ошибок (confusion matrix) и ROC-кривую. Для расчёта ROC-AUC использовать вероятности принадлежности к положительному классу, а не только итоговые метки 0/1. Порог 0,5 допускается как начальный; если порог изменяется, обосновать его выбор на валидационной выборке.

Значения 0,80 являются рекомендуемыми учебными ориентирами, а не обязательным условием зачёта. Если один или несколько показателей ниже ориентира, необходимо объяснить возможные причины и проанализировать компромисс между Recall и Precision.

6.2. Многоклассовая классификация

Для каждого класса вычислить Precision, Recall и F1-score, а также представить агрегированные значения macro average и weighted average. Вычислить Balanced Accuracy как среднее значение Recall по всем классам. Для каждой модели привести матрицу ошибок.

ROC-AUC рассчитывать по схеме One-vs-Rest (OvR) с использованием вероятностей для каждого класса. Представить ROC-кривые всех классов для лучшей модели и указать AUC каждого класса; при возможности привести macro-average AUC.

Для многоклассовой задачи ориентир Balanced Accuracy и macro ROC-AUC — желательно не ниже 0,80. Это ориентир, а не обязательный порог. При дисбалансе классов обязательно анализировать метрики каждого класса отдельно: высокая общая Accuracy может скрывать низкое качество распознавания редкого класса.

6.3. Регрессия

Метрика	Смысл	Критерий интерпретации
MSE	Среднее квадратов разностей между истинными и предсказанными значениями.	Чем ближе к 0, тем лучше. Универсального порога нет; единицы измерения — квадрат единиц целевой переменной.
MAE	Среднее абсолютное отклонение прогноза от истинного значения.	Чем ближе к 0, тем лучше. Интерпретировать в единицах целевой переменной.
R^2	Доля дисперсии целевой переменной, объясняемая моделью относительно прогноза средним значением.	Желательно $\geq 0{,}80$; 1 — идеальное соответствие, 0 — уровень прогноза средним, значение < 0 — хуже такого базового прогноза.

Для MSE и MAE фиксированные минимальные значения не устанавливаются: они зависят от масштаба и распределения целевого признака. При сравнении моделей на одном и том же наборе данных предпочтительны меньшие MSE и MAE и большее R^2. Если целевая переменная масштабировалась, перед вычислением метрик необходимо вернуть прогнозы и истинные значения к исходному масштабу.

Значение $R^2 \geq 0{,}80$ является рекомендуемым ориентиром, но не обязательным условием зачёта. Отрицательное R^2 возможно и должно быть корректно интерпретировано.

6.4. Базовые модели и проверка переобучения

Для корректного сравнения обязательно обучить базовую модель: DummyClassifier (например, most_frequent или prior) для классификации и DummyRegressor (например, mean) для регрессии. Сравнить нейросетевые модели с базовой моделью по соответствующим метрикам.

Сопоставить значения функции потерь и метрик на обучающей и валидационной выборках, проанализировать графики обучения. Признаки переобучения: заметно лучшие результаты на обучающей выборке при ухудшении на валидационной, рост validation loss при продолжении снижения training loss. При выявлении переобучения рассмотреть уменьшение сложности сети, регуляризацию, Dropout или Early Stopping.

7. Порядок выполнения работы

1. Определить индивидуальный вариант и скачать соответствующие три набора данных.
2. Провести разведочный анализ каждого набора данных и зафиксировать результаты.
3. Определить входные признаки и целевую переменную; исключить признаки с утечкой целевой информации.
4. Разделить данные на train/validation/test в рекомендуемой пропорции 70/15/15; для классификации сохранить доли классов.
5. Построить конвейер предобработки: обработка пропусков, кодирование категорий, масштабирование числовых признаков.
6. Для каждой задачи разработать не менее трёх архитектур MLP и обучить их с сопоставимыми условиями.
7. Подобрать параметры по валидационной выборке; сохранить историю обучения и лучшие веса.
8. Сравнить модели с базовой моделью, вычислить требуемые метрики и построить необходимые графики.
9. Выбрать лучшую модель для каждой задачи и один раз оценить её на тестовой выборке.
10. Сформулировать выводы о качестве, ограничениях, влиянии архитектуры и возможных направлениях улучшения.

8. Требования к отчёту (презентации)

11. Титульный лист: дисциплина, номер и название лабораторной работы, ФИО студента, группа, дата.
12. Цель и задачи работы; номер индивидуального варианта.
13. Описание трёх наборов данных: источник, объём, признаки, целевая переменная, распределение классов или статистика целевого признака.
14. Описание предварительной обработки: удалённые/преобразованные признаки, обработка пропусков, кодирование, масштабирование, способ разделения данных.
15. Таблица исследованных архитектур и гиперпараметров для каждой из трёх задач.
16. Графики обучения (training/validation loss; при наличии — дополнительные метрики) для сравниваемых моделей или как минимум для лучшей модели каждой задачи.
17. Результаты классификации: таблицы метрик по моделям; для многоклассовой задачи — метрики по каждому классу и macro/weighted averages; матрицы ошибок; ROC-кривые и AUC.
18. Результаты регрессии: таблица MSE, MAE и R^2 для всех исследованных моделей.
19. Сравнение с базовыми моделями и анализ переобучения.
20. Обоснование выбора лучшей архитектуры отдельно для бинарной классификации, многоклассовой классификации и регрессии.
21. Заключение: достигнутые результаты, причины недостижения ориентиров (если применимо), ограничения и возможные улучшения.
22. Листинг программного кода или ссылка на приложенный Jupyter Notebook. Код должен запускаться и содержать комментарии к основным этапам.

9. Критерии оценивания

Критерий	Доля
Корректная загрузка данных, анализ и отсутствие утечки данных	15%
Корректная предобработка и разделение на выборки	15%
Реализация и исследование не менее трёх архитектур для каждой задачи	25%
Корректный расчёт метрик, графиков и сравнение с базовыми моделями	20%
Анализ результатов, переобучения и обоснование выбора моделей	15%
Качество отчёта, воспроизводимость и работоспособность кода	10%

Важно: достижение рекомендуемого значения 0,80 не является самостоятельным обязательным условием получения зачёта. Оцениваются корректность методики, качество проведённого эксперимента, полнота анализа и обоснованность выводов. Некорректное завышение метрик вследствие утечки данных или оценки на обучающей выборке является существенной методической ошибкой.

10. Контрольные вопросы

23. Что такое полносвязная нейронная сеть прямого распространения (MLP)?
24. Какую роль выполняют входной, скрытые и выходной слои?
25. Чем отличаются задачи бинарной и многоклассовой классификации от регрессии?
26. Почему данные необходимо разделять на обучающую, валидационную и тестовую выборки?
27. Что такое утечка целевой информации (data leakage)? Приведите пример.
28. Для чего выполняются кодирование категориальных признаков и масштабирование числовых признаков?
29. Как выбор функции активации выходного слоя связан с типом решаемой задачи?
30. Чем отличаются Binary Crossentropy, Categorical Crossentropy и Mean Squared Error?
31. Что такое эпоха, размер пакета (batch size) и скорость обучения (learning rate)?
32. Какую роль выполняет оптимизатор Adam?
33. Что такое переобучение и как его обнаружить по графикам обучения?

34. Какие методы регуляризации применяются в нейронных сетях?
35. Что характеризуют Precision и Recall? В чём состоит компромисс между ними?
36. Что показывает Balanced Accuracy и чем она отличается от обычной Accuracy?
37. Что характеризует ROC-кривая и как интерпретируется ROC-AUC?
38. Почему для многоклассовой классификации применяют подход One-vs-Rest при построении ROC-кривых?
39. Чем отличаются macro average и weighted average?
40. Что показывает матрица ошибок (confusion matrix)?
41. Что характеризуют MSE и MAE? Почему их значения зависят от масштаба целевой переменной?
42. Как интерпретировать R^2, в том числе отрицательное значение?
43. Для чего нужны DummyClassifier и DummyRegressor?
44. Почему тестовую выборку нельзя использовать для подбора гиперпараметров?
45. Каким образом дисбаланс классов влияет на оценку качества классификатора?
46. Как определить, что увеличение числа слоёв или нейронов не улучшает модель?
47. Какие сведения необходимо привести, чтобы эксперимент можно было воспроизвести?

11. Рекомендуемый формат итоговых таблиц

Таблица A. Классификация

Модель	Recall	Precision	Balanced Accuracy	ROC-AUC	Примечание
MLP-1					
MLP-2					
MLP-3					
Базовая модель					

Таблица B. Многоклассовая классификация

Модель	Метрика	Класс 1	Класс 2	Класс 3/…	Macro avg	Weighted avg
MLP-1	Precision					
MLP-1	Recall					
MLP-1	F1-score					
MLP-2/3	Аналогично					

Таблица C. Регрессия

Модель	MSE ↓	MAE ↓	R^2 ↑	Вывод
MLP-1				
MLP-2				
MLP-3				
DummyRegressor				

Примечания по методике

1. В задании используется термин Balanced Accuracy вместо неоднозначного Weighted Accuracy. Если в программном коде рассчитывается другая метрика, её необходимо назвать точно и привести формулу.

2. Для бинарной классификации положительный класс должен быть явно определён: Diabetes — объединённые классы 1 и 2; Bank Marketing — yes.

3. В наборе Bike Sharing Dataset целевой признак дневной аренды — cnt. Обозначение Area в прежней редакции было ошибочным.

4. Метрики следует вычислять на одной и той же тестовой выборке для всех сравниваемых моделей. Округление результатов — до 3–4 знаков после запятой.

5. Для регрессии сравнение MSE и MAE корректно только при одинаковом масштабе целевой переменной.