ЛАБОРАТОРНАЯ РАБОТА № 2

ОБУЧЕНИЕ НЕЙРОСЕТЕВЫХ МОДЕЛЕЙ ДЛЯ АНАЛИЗА И ПРОГНОЗИРОВАНИЯ ВРЕМЕННЫХ РЯДОВ

1. Цель работы

Получить практические навыки подготовки временных рядов и построения нейросетевых регрессионных моделей для прогнозирования метеорологических показателей. Исследовать возможности полносвязных сетей прямого распространения (MLP), рекуррентных сетей SimpleRNN, а также сетей с ячейками LSTM и GRU.

2. Задачи работы

- получить исторические ежедневные метеорологические данные для назначенного города и выполнить их первичный анализ;
- сформировать обучающие примеры методом скользящего временного окна (sliding window);
- реализовать четыре типа регрессионных моделей: MLP (базовая модель без рекуррентного слоя), SimpleRNN, LSTM или GRU, а также модель с двумя последовательными рекуррентными слоями LSTM/GRU;
- решить две задачи прогнозирования: температуры на следующий день и средней температуры за следующие семь дней;
- исследовать влияние длины входного временного окна, числа нейронов/ячеек, глубины сети, оптимизатора и Dropout;
- сравнить модели с простыми базовыми прогнозами, оценить качество на тестовом временном интервале и проанализировать переобучение.

3. Индивидуальные варианты

Город залается по варианту, который определен преподавателем:

Последняя цифра	Город для анализа
0 или 5	Волгоград
1 или 6	Калининград
2 или 7	Сочи
3 или 8	Хабаровск
4 или 9	Якутск

Все студенты выполняют обе задачи прогнозирования на данных назначенного города. Для обеспечения сопоставимости результатов рекомендуется использовать один и тот же источник данных и одинаковый временной интервал для всех городов.

4. Источник и состав данных

Использовать исторические ежедневные метеорологические наблюдения. Рекомендуемый источник — Open-Meteo Historical Weather API (архив исторической погоды): https://open-meteo.com/en/docs/historical-weather-api. Допускается другой открытый источник, если студент указывает ссылку, название набора, единицы измерения, период и способ получения данных.

Город	Широта	Долгота
Волгоград	48.7080	44.5133
Калининград	54.7104	20.4522

Сочи	43.5855	39.7231
Хабаровск	48.4827	135.0838
Якутск	62.0355	129.6755

Основной целевой показатель — среднесуточная температура воздуха (например, temperature_2m_mean), °C. Рекомендуемый период — не менее 5 полных лет ежедневных данных; предпочтительно 8–10 лет, если источник позволяет. Необходимо использовать единый период и одинаковые правила загрузки для всех сравниваемых моделей.

В базовом эксперименте входным признаком является история среднесуточной температуры. Дополнительный эксперимент может включать другие доступные метеорологические признаки (например, минимальную и максимальную температуру, осадки, скорость ветра), но их перечень должен быть одинаковым для сравниваемых архитектур. Прогнозируемая температура и признаки будущих дат не должны попадать во вход модели.

Если в данных имеются пропуски, дубликаты или нерегулярные даты, необходимо выявить и описать их. Нельзя интерполировать значения с использованием будущих наблюдений через границу обучающего и тестового интервалов.

5. Постановка задач прогнозирования

5.1. Задача A — прогноз на следующий день

По значениям среднесуточной температуры за предыдущие L дней спрогнозировать среднесуточную температуру следующего дня. Для каждого момента времени t входом служит последовательность [T(t-L), …, T(t-1)], целевым значением — T(t).

5.2. Задача B — прогноз средней температуры на следующие семь дней

По значениям температуры за предыдущие L дней спрогнозировать среднюю температуру за следующие семь календарных дней: y(t) = mean(T(t), T(t+1), …, T(t+6)). Модель формирует одно скалярное предсказание на каждый момент прогноза. Необходимо явно указать, что это прогноз недельного среднего, а не семь отдельных дневных прогнозов.

Для обеих задач исследовать несколько длин входного окна L, например 7, 14, 30 и 60 дней. Допускаются другие значения с обоснованием. Одинаковые границы временных выборок должны использоваться при сравнении моделей.

6. Подготовка временных рядов и разделение данных

- Отсортировать наблюдения по дате по возрастанию; проверить уникальность дат, периодичность и пропуски.
- Построить график временного ряда и описать сезонность, тренд, диапазон значений и возможные аномалии.
- Сформировать входные последовательности скользящим окном. Для рекуррентных сетей формат входа: (число примеров, длина окна, число признаков). Для MLP последовательность можно преобразовать в вектор фиксированной длины.
- Разделить данные строго хронологически, без случайного перемешивания: рекомендуемая пропорция 70% train, 15% validation, 15% test. Более поздние даты должны относиться к validation и test.
- При формировании окон обеспечить, чтобы целевые значения обучающих примеров не выходили за границу обучающего периода. Аналогично не допускать использования целевых значений тестового периода при обучении и подборе параметров.

- Масштабирование (например, StandardScaler или MinMaxScaler) обучать только на обучающем интервале; затем применять те же параметры к validation и test. Для интерпретации MAE и RMSE возвращать значения к исходной шкале °C.
- Не перемешивать временные последовательности при разбиении. При обучении допускается shuffle обучающих окон, если порядок внутри каждого окна сохранён и разбиение по времени выполнено заранее.
- Зафиксировать random seed и указать точные даты начала и окончания каждого интервала.

Важно: для задачи недельного среднего целевой интервал состоит из семи будущих дней. При разделении необходимо учитывать горизонт прогноза, чтобы целевые значения обучающих окон не пересекали validation/test-интервалы.

7. Архитектуры нейронных сетей

Для каждой из двух задач необходимо реализовать и сравнить все четыре типа моделей:

Модель	Архитектура и назначение
Модель 1 — MLP	Полносвязная сеть прямого распространения. Вход — вектор значений окна длины L; один или несколько Dense-слоёв; выходной Dense(1) с линейной активацией. Используется как базовая нейросетевая архитектура.
Модель 2 — SimpleRNN	Входная последовательность (L, число признаков), один рекуррентный слой SimpleRNN, затем выходной Dense(1).
Модель 3 — LSTM или GRU	Один слой LSTM либо GRU, затем выходной Dense(1). Студент указывает, какой тип ячейки использован.
Модель 4 — Stacked LSTM/GRU	Два последовательных рекуррентных слоя LSTM или GRU. Первый слой должен возвращать последовательность (return_sequences=True), второй формирует итоговое представление; далее Dense(1).

В исходной формулировке задания было указано «регрессор встречного распространения». В данной редакции термин уточнён как «полносвязный регрессор прямого распространения (MLP)», поскольку он служит нерекуррентной базовой архитектурой для сравнения с RNN/LSTM/GRU.

Для каждой архитектуры исследовать не менее двух конфигураций числа нейронов/ячеек (например, 32 и 64) либо обосновать иной диапазон. Также исследовать минимум два значения длины входного окна. Не требуется перебирать все возможные комбинации, но план экспериментов должен позволять оценить влияние выбранных параметров.

Для всех моделей использовать линейную активацию выходного нейрона, поскольку решается задача регрессии непрерывной температуры. Рекомендуемая функция потерь — MSE; допускается MAE или Huber loss при обосновании. В качестве оптимизатора рекомендуется Adam; дополнительно сравнить как минимум один другой оптимизатор (например, RMSprop или SGD).

Провести эксперимент с Dropout: сравнить вариант без Dropout и как минимум один вариант с Dropout (например, 0,1–0,3). Dropout размещать после Dense-слоя или рекуррентного слоя с корректной настройкой recurrent_dropout при необходимости. Указать, какие слои и значения вероятности прореживания использованы.

Для ограничения переобучения рекомендуется EarlyStopping с контролем validation loss и восстановлением лучших весов (restore_best_weights=True). Число эпох, batch size, learning rate и patience указать в отчёте.

8. Базовые прогнозы для сравнения

Нейросетевые модели необходимо сравнить как минимум с двумя простыми базовыми подходами:

- Persistence / Naive forecast: прогноз температуры на следующий день равен последнему известному значению температуры. Для недельного горизонта базовый недельный прогноз можно задать как среднее температуры за последние семь известных дней.
- Seasonal naive (если период данных позволяет): прогноз равен значению того же календарного дня предыдущего года (или ближайшего доступного дня год назад). Метод и правила обработки високосных дат описать.

Если нейросеть не превосходит базовый прогноз, необходимо обсудить возможные причины: недостаточный объём данных, сезонность, длина окна, шум, переобучение или неподходящие гиперпараметры.

9. Метрики качества и критерии интерпретации

Метрика	Интерпретация	Рекомендуемый ориентир
MAE	Средняя абсолютная ошибка прогноза, в °C. Показывает среднюю величину ошибки в исходных единицах.	Чем ближе к 0, тем лучше; универсального порога нет.
MSE	Средний квадрат ошибки, в °C². Сильнее штрафует крупные отклонения.	Чем ближе к 0, тем лучше; универсального порога нет.
RMSE	Корень из MSE, в °C. Более интерпретируемая мера крупных ошибок.	Чем ближе к 0, тем лучше; универсального порога нет.
R^2	Доля вариации целевой переменной, объясняемая моделью относительно прогноза средним значением.	Желательно $\geq 0{,}80$; значение 1 — идеальное, 0 — уровень среднего, <0 — хуже среднего.

В исходном задании обязательными метриками указаны R^2, MSE и MAE. В этой редакции дополнительно включён RMSE, поскольку он выражается в тех же единицах, что и температура (°C), и облегчает интерпретацию ошибки. Если преподаватель не требует RMSE, его можно представить как дополнительную метрику.

Значение $R^2 \geq 0{,}80$ является ориентиром, а не обязательным условием зачёта. Для MSE, MAE и RMSE фиксированные минимальные пороги не устанавливаются: значения зависят от города, периода, горизонта прогноза и масштаба целевого показателя. Сравнивать модели следует на одинаковых тестовых датах и в исходных единицах измерения.

Для обеих задач метрики рассчитывать отдельно. Не объединять результаты прогноза на следующий день и недельного среднего в одну таблицу без явного разделения.

10. Порядок выполнения работы

1. Определить город по индивидуальному варианту.
2. Загрузить ежедневные исторические данные и указать источник, период и состав признаков.
3. Провести анализ качества данных и визуализацию временного ряда.
4. Сформировать два целевых ряда: температура следующего дня и средняя температура следующих семи дней.
5. Сформировать скользящие окна нескольких длин; разделить данные хронологически на train/validation/test.
6. Обучить MLP, SimpleRNN, LSTM/GRU и двухслойную LSTM/GRU-модель для каждой задачи.
7. Провести эксперименты с числом ячеек/нейронов, длиной окна, оптимизатором и Dropout.
8. Использовать validation для выбора архитектуры и гиперпараметров; применить EarlyStopping при необходимости.
9. Построить базовые прогнозы и сравнить их с нейросетевыми моделями.
10. Оценить выбранные модели на тестовом интервале, вычислить метрики и построить графики «факт — прогноз» и «ошибка — время».

11. Проанализировать результаты, устойчивость моделей и признаки переобучения; сформулировать выводы.

11. Требования к отчёту (презентации)

1. Титульный лист, цель и задачи работы, индивидуальный вариант и город.
2. Описание источника данных, периода наблюдений, целевого показателя, признаков, единиц измерения и объёма выборки.
3. Результаты первичного анализа данных: пропуски, дубликаты, описательная статистика и график временного ряда.
4. Описание формирования скользящих окон: длина L, горизонт прогноза, определение целевой переменной для обеих задач.
5. Точные даты и размеры train/validation/test; описание масштабирования и мер предотвращения утечки данных.
6. Таблица архитектур и гиперпараметров всех моделей: тип слоя, число нейронов/ячеек, оптимизатор, learning rate, batch size, число эпох, Dropout, EarlyStopping.
7. Графики обучения (training loss и validation loss) для выбранных моделей.
8. Таблицы результатов отдельно для прогноза на следующий день и прогноза недельного среднего: MSE, MAE, RMSE, R^2 для всех моделей и базовых прогнозов.
9. Графики фактических и прогнозируемых значений на тестовом интервале; графики ошибок (остатков).
10. Сравнение моделей, анализ переобучения, обоснование выбора лучшей модели для каждой задачи.
11. Заключение: достигнутые результаты, ограничения эксперимента, причины недостижения ориентиров (если применимо), возможные улучшения.
12. Программный код (Jupyter Notebook или Python-файлы), который позволяет воспроизвести загрузку/подготовку данных, обучение и оценку моделей.

12. Критерии оценивания

Критерий	Доля
Получение, описание и анализ временного ряда; корректная работа с датами и пропусками	15%
Корректное формирование окон и хронологическое разделение без утечки данных	20%
Реализация четырёх архитектур для обеих задач прогнозирования	25%
Эксперименты с длиной окна, параметрами сети, оптимизатором и Dropout	15%
Корректный расчёт метрик, сравнение с базовыми прогнозами и визуализация	15%
Анализ результатов, выводы, качество отчёта и воспроизводимость кода	10%

Важно: достижение $R^2 \geq 0{,}80$ не является самостоятельным обязательным условием зачёта. Оцениваются корректность постановки эксперимента, отсутствие утечки данных, полнота сравнения, качество анализа и обоснованность выводов.

13. Контрольные вопросы

1. Что такое временной ряд и какие компоненты сезонности и тренда могут присутствовать в метеорологических данных?
2. Чем прогнозирование временных рядов отличается от обычной регрессии на независимых наблюдениях?
3. Что такое скользящее временное окно и как формируются входные последовательности?
4. Как длина входного окна влияет на качество прогноза?
5. Почему временной ряд нельзя случайным образом разделять на обучающую и тестовую выборки?

6. Что такое утечка данных в задаче прогнозирования временных рядов?
7. Для чего масштабируют входные признаки и почему scaler обучают только на train?
8. Чем MLP отличается от SimpleRNN?
9. Как устроена рекуррентная связь в SimpleRNN?
10. Какие проблемы градиента затухающего и взрывающегося возникают при обучении RNN?
11. Какие элементы ячейки LSTM позволяют сохранять долгосрочную информацию?
12. Чем GRU отличается от LSTM?
13. Для чего в первом слое stacked LSTM/GRU используют return_sequences=True?
14. Что такое Dropout и как он помогает бороться с переобучением?
15. Как работает EarlyStopping и зачем восстанавливать лучшие веса?
16. Какую функцию потерь и выходную активацию целесообразно использовать для регрессии температуры?
17. Что характеризуют MSE, MAE и RMSE? В каких единицах измеряется каждая метрика?
18. Как интерпретировать R^2, включая отрицательное значение?
19. Почему нейросетевую модель необходимо сравнивать с наивным прогнозом?
20. Как определить, что модель переобучилась, по графикам training loss и validation loss?
21. Почему прогноз недельного среднего является задачей с горизонтом семь дней?
22. Чем отличается прогноз средней температуры за следующие семь дней от прогноза семи отдельных дневных температур?
23. Почему при сравнении моделей необходимо использовать одинаковые тестовые даты?
24. Какие дополнительные признаки погоды могут улучшить прогноз и какие риски возникают при их использовании?
25. Какие параметры эксперимента необходимо зафиксировать для воспроизводимости?

14. Рекомендуемые таблицы для отчёта

Таблица 1. Сравнение моделей — прогноз на следующий день

Модель	Длина окна L	Число ячеек/нейронов	Dropout	MAE	MSE	RMSE	R^2
MLP							
SimpleRNN							
LSTM/GRU							
Stacked LSTM/GRU							
Naive forecast							

Таблица 2. Сравнение моделей — прогноз недельного среднего

Модель	Длина окна L	Число ячеек/нейронов	Dropout	MAE	MSE	RMSE	R^2
MLP							
SimpleRNN							
LSTM/GRU							
Stacked LSTM/GRU							
Naive forecast							