ЛАБОРАТОРНАЯ РАБОТА № 3

СВЁРТОЧНЫЕ НЕЙРОННЫЕ СЕТИ И ПЕРЕНОС ОБУЧЕНИЯ ДЛЯ КЛАССИФИКАЦИИ ИЗОБРАЖЕНИЙ

1. Цель работы

Получить практические навыки подготовки наборов изображений, построения и обучения свёрточных нейронных сетей (CNN), оценки качества моделей классификации, применения аугментации и регуляризации, а также использования предварительно обученных на ImageNet моделей с переносом обучения (transfer learning) и тонкой настройкой (fine-tuning).

2. Задачи работы

1. Изучить структуру выбранного набора изображений и сформировать три класса согласно индивидуальному варианту.
2. Подготовить данные: проверить изображения и метки, привести изображения к единому размеру и формату, разделить данные на обучающую, валидационную и тестовую выборки.
3. Построить и обучить собственную CNN для бинарной классификации классов 0 и 1.
4. Исследовать влияние архитектуры сети, числа фильтров, глубины сети, оптимизатора и Dropout на качество и устойчивость обучения.
5. Применить аугментацию только к обучающим данным и сравнить результаты с обучением без аугментации.
6. Выбрать и сохранить лучшую модель бинарной классификации.
7. Построить трёхклассовый классификатор на основе предварительно обученной на ImageNet свёрточной сети.
8. Сравнить два режима transfer learning: обучение классификационной «головы» при замороженной свёрточной основе и fine-tuning с частичной разморозкой основы.
9. Оценить модели на отложенной тестовой выборке, сравнить метрики, построить графики обучения и сформулировать выводы.

3. Теоретические сведения

3.1. Свёрточная нейронная сеть

Свёрточная нейронная сеть (Convolutional Neural Network, CNN) предназначена для обработки изображений. Свёрточные слои извлекают локальные признаки (границы, текстуры, формы), функции активации вводят нелинейность, слои подвыборки уменьшают пространственное разрешение, а полносвязная часть формирует итоговое решение о классе.

Типичная архитектура для данной работы включает блоки Conv2D → ReLU → MaxPooling2D, затем Flatten или GlobalAveragePooling2D, Dropout и выходной классификационный слой. Увеличение числа фильтров по мере углубления сети позволяет извлекать более сложные

признаки, однако чрезмерное увеличение глубины и числа параметров может приводить к переобучению.

3.2. Dropout и аугментация

Dropout случайным образом отключает часть нейронов во время обучения и тем самым снижает взаимную адаптацию признаков. Значение Dropout выбирается экспериментально (например, 0,2–0,5). Слишком сильное прореживание может привести к недообучению.

Аугментация искусственно увеличивает разнообразие обучающих изображений с помощью небольших поворотов, отражений, сдвигов, масштабирования и изменения яркости. Преобразования должны сохранять смысл класса. Аугментация применяется только к обучающей выборке; валидационные и тестовые изображения не должны случайно изменяться.

3.3. Перенос обучения

При transfer learning используется свёрточная основа модели, предварительно обученная на ImageNet. На первом этапе основа замораживается, а новая классификационная «голова» обучается на выбранном наборе данных. На втором этапе размораживается верхняя часть основы и выполняется fine-tuning с малой скоростью обучения. Это позволяет адаптировать извлечённые признаки к новой предметной области, не разрушая уже полученные представления.

4. Индивидуальные варианты

Номер варианта определяется последней цифрой номера зачётной книжки (или студенческого билета). Для каждого варианта используются указанные три класса. В бинарной задаче применяются только классы 0 и 1; класс 2 исключается. В многоклассовой задаче используются все три класса.

Последняя цифра	Набор данных	Класс 0	Класс 1	Класс 2	Источник
0 или 5	Plant Disease	Tomato	Potato	Pepper	https://www.kaggle.com/datasets/emmarex/plantdisease
1 или 6	Weed Detection in Soybean Crops	soybean	soil	grass	https://www.kaggle.com/datasets/fpeccia/weed-detection-in-soybean-crops
2 или 7	Plant Disease	Potato__Late_blight	Potato__healthy	Potato__Early_blight	https://www.kaggle.com/datasets/emmarex/plantdisease

3 или 8	Plant Disease	Pepper_bell_Bacterial_spot	Potato__healthy	Pepper_bell_healthy	https://www.kaggle.com/datasets/emmarex/plantdisease
4 или 9	Plant Disease	Tomato_YellowLeaf_Curl_virus	Tomato_healthy	Tomato_Septoria_Leaf_spot	https://www.kaggle.com/datasets/emmarex/plantdisease

Примечание. Названия папок в скачанном архиве могут отличаться регистром, пробелами или символами подчёркивания. Перед загрузкой данных необходимо проверить фактическую структуру каталогов и сопоставить её с названиями классов. Не включайте посторонние папки и изображения других классов.

5. Порядок выполнения работы

Этап 1. Загрузка и анализ данных

10. Скачать набор данных по ссылке своего варианта и выделить изображения только трёх заданных классов.
11. Вывести количество изображений в каждом классе, проверить корректность меток и наличие повреждённых файлов.
12. Показать не менее пяти примеров изображений каждого класса с подписями. Оценить различия внутри класса и сходство между классами.
13. Проверить баланс классов. Если количество изображений сильно различается, отразить это в отчёте и при необходимости использовать class weights, не изменяя тестовую выборку.

Этап 2. Предварительная обработка и разбиение

Рекомендуемое разбиение: 70 % — обучающая выборка, 15 % — валидационная, 15 % — тестовая. Разбиение следует выполнять стратифицированно, сохраняя доли классов. Если в наборе имеются серии почти одинаковых изображений или изображения одного объекта/сцены, связанные изображения необходимо помещать в одну и ту же часть выборки, чтобы исключить утечку данных.

- Привести изображения к единому размеру, рекомендуемое значение — 224 × 224 пикселя, и к трёхканальному RGB-формату.
- Преобразовать пиксели к типу float и нормировать значения в диапазон [0; 1] для собственной CNN.
- Для моделей ImageNet использовать предусмотренную выбранной архитектурой функцию preprocess_input; не применять одновременно несовместимую с ней нормализацию.
- Зафиксировать random seed и сохранить списки файлов/индексов каждой выборки для воспроизводимости эксперимента.

Важно: тестовая выборка не используется при подборе архитектуры, гиперпараметров, эпох и порога классификации. Все решения принимаются по обучающей и валидационной выборкам; тестовая выборка используется для итоговой оценки.

Этап 3. Бинарная классификация собственной CNN

Сформировать бинарный набор только из классов 0 и 1. Класс 0 кодируется меткой 0, класс 1 — меткой 1. Построить не менее трёх вариантов CNN, последовательно изменяя один или несколько параметров архитектуры.

Эксперимент	Пример конфигурации	Что исследуется
CNN-1	2 свёрточных блока: 32 и 64 фильтра; MaxPooling; Dense 128; Dropout 0,3	Базовая модель
CNN-2	3 свёрточных блока: 32, 64 и 128 фильтров; GlobalAveragePooling; Dense 128	Влияние глубины и числа фильтров
CNN-3	Архитектура CNN-2 с Dropout 0,5 и/или L2-регуляризацией	Влияние регуляризации

Для бинарной классификации рекомендуется выходной слой Dense(1, activation='sigmoid') и функция потерь binary_crossentropy. В качестве оптимизатора можно использовать Adam; начальную скорость обучения, например 0,001, следует обосновать и при необходимости изменить.

Для каждого эксперимента сохранять историю обучения, время обучения и лучшие веса по значению val_loss или выбранной основной валидационной метрике. Использовать EarlyStopping и ModelCheckpoint; при необходимости ReduceLROnPlateau.

Этап 4. Аугментация данных

Повторить обучение выбранной CNN с аугментацией обучающих изображений. Рекомендуются небольшие повороты, горизонтальное отражение (если оно допустимо для предметной области), небольшое масштабирование и сдвиги. Для растительных изображений не использовать преобразования, которые меняют диагностически значимые признаки.

Сравнить модель до и после аугментации по значениям метрик на одной и той же тестовой выборке. Указать, улучшилась ли обобщающая способность и уменьшился ли разрыв между обучающими и валидационными показателями.

Этап 5. Многоклассовая классификация с transfer learning

Использовать все три класса варианта. Выбрать одну предварительно обученную архитектуру, например MobileNetV2, ResNet50, VGG16, InceptionV3 или Xception. Для учебного эксперимента рекомендуется начать с MobileNetV2 или ResNet50, учитывая доступные вычислительные ресурсы.

Добавить к свёрточной основе классификационную голову: GlobalAveragePooling2D, Dropout и Dense(3, activation='softmax'). Использовать categorical_crossentropy для one-hot меток или sparse_categorical_crossentropy для целочисленных меток.

Режим	Настройки	Требуемый результат
A. Замороженная основа	Все слои backbone заморожены; обучается только новая классификационная голова; ориентировочная скорость обучения 10^{-3}	Оценить качество переноса признаков без изменения основы

B. Fine-tuning	Разморозить верхние слои backbone (например, последние 20–30 слоёв; конкретное число зависит от архитектуры), нижние слои оставить замороженными; использовать малую скорость обучения, например 10^{-5}–10^{-4}	Оценить, улучшает ли адаптация основы качество на целевых классах

Перед повторной компиляцией модели после изменения trainable необходимо выполнить compile заново. При fine-tuning использовать малую скорость обучения и контролировать val_loss: слишком агрессивное обновление весов может ухудшить предварительно обученные признаки.

Сохранить лучшую модель каждого режима. Сопоставить их результаты на тестовой выборке и объяснить, какой режим оказался эффективнее.

Этап 6. Оценка качества моделей

Для каждой лучшей модели привести значения метрик на тестовой выборке. Одной Accuracy недостаточно, особенно при дисбалансе классов.

Метрика	Назначение
Accuracy	Доля правильно классифицированных изображений
Precision	Доля правильных положительных предсказаний среди всех предсказаний данного класса
Recall	Доля объектов класса, найденных моделью
F1-score	Гармоническое среднее Precision и Recall; для нескольких классов привести macro-F1
Confusion matrix	Показывает распределение правильных и ошибочных предсказаний по классам

Для бинарной модели дополнительно привести ROC-кривую и ROC-AUC. Указать, какой класс считается положительным. Для трёхклассовой модели привести матрицу ошибок и Precision, Recall, F1-score по каждому классу, а также macro-average. Все итоговые метрики рассчитывать по тестовой выборке.

Построить графики Loss и Accuracy для обучающей и валидационной выборок по эпохам. Для моделей transfer learning такие графики привести отдельно для режима замороженной основы и fine-tuning.

6. Требования к экспериментам и оформлению результатов

- В экспериментах сравнивать модели при одинаковом разбиении данных и сопоставимых условиях обучения.
- В таблице параметров указывать размер входного изображения, архитектуру, число слоёв/фильтров, Dropout, оптимизатор, learning rate, batch size, число эпох и фактическое число эпох до остановки.
- Фиксировать случайное зерно (seed), версии основных библиотек и аппаратную среду.

- Не выбирать лучшую модель по тестовым метрикам. Выбор выполнять по валидационной выборке, а тест использовать один раз для итогового сравнения.
- Сохранять веса/модель, историю обучения, графики, матрицы ошибок и таблицы метрик.
- В программном коде указывать назначение основных блоков, параметры экспериментов и комментарии к нестандартным решениям.

7. Содержание отчёта (презентации)

1. Титульный лист: название работы, ФИО, группа, вариант, дата выполнения.
2. Цель и задачи лабораторной работы.
3. Описание набора данных: источник, выбранные классы, количество изображений по классам, примеры изображений и анализ баланса.
4. Описание предобработки и разбиения: размеры выборок, способ стратификации, размер изображений, нормализация и аугментация.
5. Описание архитектур собственной CNN и таблица гиперпараметров для бинарной классификации.
6. Графики Loss и Accuracy для обучающей и валидационной выборок; сравнение моделей до и после Dropout и аугментации.
7. Описание выбранной ImageNet-архитектуры и двух режимов transfer learning.
8. Сводные таблицы тестовых метрик, ROC-кривая и матрица ошибок для бинарной модели; матрицы ошибок и метрики по классам для трёхклассовых моделей.
9. Сравнительный анализ результатов и объяснение причин различий между моделями.
10. Листинг программного кода с комментариями или ссылка на приложение/репозиторий с указанием используемых файлов.
11. Выводы по каждой задаче работы.

8. Контрольные вопросы

1. Как устроен свёрточный слой и какую роль выполняют фильтры (ядра) свёртки?
2. Для чего применяются функции активации ReLU и Softmax?
3. Чем отличаются MaxPooling и AveragePooling?
4. Что такое переобучение и по каким признакам его можно обнаружить на графиках обучения?
5. Как работает Dropout и почему он применяется только во время обучения?
6. Что такое аугментация изображений? Почему её нельзя применять к тестовой выборке при обучении?
7. Для чего данные разделяют на обучающую, валидационную и тестовую выборки?
8. Что такое утечка данных (data leakage)? Приведите пример для классификации изображений.
9. Чем отличаются бинарная и многоклассовая классификация с точки зрения выходного слоя и функции потерь?
10. Что такое transfer learning и fine-tuning? В чём различие этих подходов?
11. Почему при fine-tuning используют меньшую скорость обучения?

12. Что означает предварительное обучение модели на ImageNet?
13. В каких случаях Accuracy может быть недостаточной метрикой качества?
14. Что показывают Precision, Recall и F1-score?
15. Как интерпретировать матрицу ошибок и ROC-AUC?

9. Критерии оценивания

Компонент работы	**Баллы**
Подготовка данных, анализ классов и корректное разбиение	15
Бинарные CNN: не менее трёх экспериментов, Dropout и сравнение	20
Аугментация и анализ её влияния	10
Transfer learning: замороженная основа и fine-tuning	20
Корректная тестовая оценка, метрики, графики и матрицы ошибок	20
Качество отчёта, воспроизводимость кода и обоснованные выводы	15
Итого	100

10. Ожидаемые результаты

По итогам работы студент должен представить две лучшие модели бинарной/трёхклассовой классификации в соответствии с заданием, сравнительные таблицы метрик, графики обучения, матрицы ошибок, программный код и аргументированные выводы. В отчёте необходимо отделять фактически полученные результаты от ожидаемых: значения метрик не задаются заранее и должны быть получены в ходе экспериментов.