ЛАБОРАТОРНАЯ РАБОТА № 4

СНИЖЕНИЕ РАЗМЕРНОСТИ ПРИЗНАКОВОГО ПРОСТРАНСТВА МЕТОДАМИ ОБУЧЕНИЯ МНОГООБРАЗИЮ

1. Цель работы

Получить практические навыки снижения размерности признакового пространства методами обучения многообразию, визуализации многомерных данных в двумерном и трёхмерном пространствах, анализа структуры классов, кластеризации полученных представлений и построения классификаторов на двумерных вложениях.

2. Задачи работы

1. Выбрать набор данных из лабораторной работы № 1, предназначенный для решения задачи многоклассовой классификации, и отобрать не менее шести непрерывных числовых признаков.
2. Выполнить предварительную обработку данных: проверить пропуски и выбросы, привести признаки к сопоставимому масштабу, сформировать матрицу признаков и вектор классов.
3. Преобразовать исходное признаковое пространство в 2D и 3D с помощью методов MDS, Isomap, LLE, t-SNE и UMAP.
4. Визуализировать полученные вложения, используя единый цвет для объектов одного исходного класса, и сравнить степень разделимости классов.
5. Выполнить кластеризацию координат каждого вложения алгоритмом K-means при числе кластеров от 3 до 6 и проанализировать состав кластеров.
6. Для каждого двумерного вложения обучить классификаторы Decision Tree и Random Forest, визуализировать границы решений и сравнить качество моделей.
7. Сопоставить методы снижения размерности по визуальному качеству, сохранению структуры данных, результатам кластеризации и классификации.
8. Сформулировать выводы о преимуществах, ограничениях и применимости рассмотренных методов.

3. Теоретические сведения

3.1. Снижение размерности и обучение многообразию

Снижение размерности — преобразование данных из пространства исходных признаков высокой размерности в пространство меньшей размерности с целью выявления структуры данных, упрощения визуального анализа и уменьшения сложности последующей обработки. Методы обучения многообразию предполагают, что данные могут располагаться около низкоразмерного многообразия, вложенного в исходное пространство.

3.2. Рассматриваемые методы

Метод	Основная идея	Особенности и параметры для исследования
MDS (Metric Multidimensional Scaling)	Размещает объекты так, чтобы попарные расстояния в низкоразмерном пространстве по возможности соответствовали исходным расстояниям.	n_components=2 или 3; metric=True; random_state; число инициализаций. Анализировать значение stress.
Isomap	Сохраняет геодезические расстояния, приближённые по графу ближайших соседей.	n_neighbors; n_components; метрика расстояния. Слишком малое/большое число соседей может нарушить структуру графа.
LLE (Locally Linear Embedding)	Сохраняет локальные линейные отношения между объектом и его ближайшими соседями.	n_neighbors; n_components; reg. Чувствителен к выбору числа соседей и шуму.
t-SNE	Сохраняет локальные вероятностные сходства между объектами и отображает их в низкую размерность.	perplexity; learning_rate; early_exaggeration; init; random_state. Хорош для визуализации локальных групп, но расстояния между удалёнными группами и размеры кластеров нельзя трактовать как точные.
UMAP	Строит граф локальных соседств и оптимизирует низкоразмерное представление, приближая локальную и глобальную структуру.	n_neighbors; min_dist; metric; n_components; random_state. Результат зависит от параметров и версии библиотеки.

Важно: координаты вложения не имеют фиксированного физического смысла. Поворот, отражение и масштаб визуализации могут изменяться между запусками. Поэтому сравнивать следует общую структуру, разделимость и количественные показатели, а не абсолютные координаты.

3.3. Кластеризация K-means

K-means разбивает объекты на K групп, минимизируя сумму квадратов расстояний объектов до центров назначенных кластеров. В данной работе кластеризация выполняется отдельно на координатах каждого 2D- и 3D-вложения при K = 3, 4, 5 и 6. Метки исходных классов не подаются алгоритму: они используются только после кластеризации для анализа состава кластеров.

3.4. Классификация и границы решений

Decision Tree формирует последовательность правил разбиения пространства признаков. Random Forest объединяет предсказания множества деревьев, обученных на случайных

подвыборках объектов и признаков. В работе входом моделей служат две координаты соответствующего двумерного вложения, а целевой переменной — исходный класс.

4. Исходные данные

Использовать набор данных и постановку многоклассовой классификации из лабораторной работы № 1. Если в лабораторной работе № 1 применялось несколько наборов, студент использует свой ранее назначенный набор и тот же состав классов.

- Отобрать не менее шести непрерывных числовых признаков. Не включать идентификаторы, текстовые поля, категориальные коды и целевую переменную.
- Указать название набора данных, источник, количество объектов, число классов, названия классов и количество объектов в каждом классе.
- Проверить типы данных, пропуски, бесконечные значения и дубликаты. Описать способ обработки пропусков и возможных выбросов.
- Построить таблицу описательной статистики выбранных признаков: среднее, стандартное отклонение, минимум, максимум.
- Проверить корреляции между признаками и при необходимости отметить признаки с высокой взаимной корреляцией.

5. Порядок выполнения работы

Этап 1. Подготовка данных

9. Загрузить данные и сформировать матрицу X из выбранных непрерывных признаков и вектор y с метками классов.
10. Удалить или корректно обработать строки с отсутствующими/некорректными значениями. Не подменять пропуски произвольными константами без обоснования.
11. Стандартизировать признаки, например с помощью StandardScaler: для каждого признака вычесть среднее и разделить на стандартное отклонение. Масштабирование особенно важно для методов, основанных на расстояниях.
12. Зафиксировать random_state и параметры экспериментов для воспроизводимости. Для больших наборов данных допускается использовать стратифицированную подвыборку, указав её размер и способ отбора.

Методы обучения многообразию чувствительны к масштабу признаков. Нельзя выполнять их на исходных признаках с существенно различающимися единицами измерения без обоснования выбранного способа масштабирования.

Этап 2. Построение 2D- и 3D-вложений

Для каждого из пяти методов построить два представления: двумерное (n_components=2) и трёхмерное (n_components=3). Таким образом, необходимо получить не менее десяти вложений.

13. Выполнить преобразование стандартизированной матрицы X методом MDS.

14. Повторить преобразование методами Isomap и LLE.
15. Построить вложения t-SNE в 2D и 3D. Для t-SNE подобрать допустимое значение perplexity с учётом числа объектов; perplexity должно быть меньше числа объектов.
16. Построить вложения UMAP в 2D и 3D. Если библиотека umap-learn не установлена, установить её в используемое виртуальное окружение.
17. Для каждого вложения построить scatter plot: цвет точки соответствует исходному классу. Для 3D использовать интерактивную или трёхмерную диаграмму.
18. Сохранить графики с заголовками, легендой, названиями осей и указанием метода и размерности.

Для корректного сравнения по возможности использовать одинаковую выборку объектов и одинаковую цветовую палитру классов на всех графиках. Если используется подвыборка, состав объектов должен быть одинаковым для всех методов.

Этап 3. Подбор параметров и анализ визуализаций

Для каждого метода провести не менее двух запусков с различающимися значениями одного или нескольких ключевых параметров. Например, для Isomap и LLE изменить n_neighbors; для t-SNE — perplexity; для UMAP — n_neighbors и min_dist; для MDS — число инициализаций или параметры оптимизации.

В отчёте привести итоговую конфигурацию каждого метода и объяснить выбор параметров. Не следует объявлять метод лучшим только на основании визуально наиболее разнесённых групп: необходимо учитывать количественные показатели и ограничения алгоритма.

- Для оценки сохранения структуры можно использовать trustworthiness (доверительность вложения), если она доступна для выбранного метода.
- Для MDS привести значение stress, если оно возвращается реализацией алгоритма.
- Отметить, какие классы визуально разделяются, какие перекрываются и наблюдаются ли внутриклассовые подгруппы.

Этап 4. Кластеризация K-means

Для каждого полученного вложения выполнить K-means отдельно при K = 3, 4, 5 и 6. Следовательно, анализируется кластеризация всех пяти методов в 2D и 3D.

19. Обучить K-means на координатах вложения без использования исходных меток классов. Для воспроизводимости задать random_state и n_init.
20. Сохранить номер кластера для каждого объекта.
21. Для каждого кластера вычислить количество и долю объектов каждого исходного класса. Доли рассчитывать внутри кластера: количество объектов данного класса в кластере / общее количество объектов кластера × 100 %.
22. Представить состав кластеров в виде таблицы сопряжённости и/или диаграммы с накоплением.
23. Визуализировать кластеры отдельным графиком, раскрашивая точки по назначенному K-means кластеру. Для 3D также показать пространственное распределение.

24. При возможности вычислить Silhouette Score для оценки компактности и разделённости кластеров. Для сопоставления с известными классами дополнительно привести Adjusted Rand Index (ARI) или Normalized Mutual Information (NMI).

Silhouette Score оценивает структуру кластеров без использования истинных классов; ARI и NMI сравнивают полученные кластеры с исходными метками. Эти показатели отвечают на разные вопросы и не должны интерпретироваться как взаимозаменяемые.

Этап 5. Классификация на двумерных вложениях

Для каждого из пяти двумерных представлений обучить две модели: Decision Tree и Random Forest. Входные признаки моделей — две координаты вложения, целевая переменная — исходная метка класса.

25. Разделить координаты и метки на обучающую и тестовую части, например в пропорции 70/30, с использованием stratify=y и фиксированного random_state.
26. Обучить Decision Tree. Исследовать ограничение глубины дерева (max_depth) и минимальное число объектов в листе (min_samples_leaf), чтобы контролировать переобучение.
27. Обучить Random Forest. Указать число деревьев (n_estimators), max_depth, max_features и random_state. При необходимости подобрать параметры по валидационной выборке или кросс-валидации.
28. Оценить Accuracy, Precision, Recall и F1-score. Для многоклассовой задачи привести macro-average и метрики по каждому классу; построить матрицу ошибок.
29. Построить границы решений на плоскости для каждой модели и каждого 2D-вложения. На графике показать фон областей предсказанных классов и реальные точки тестовой выборки.
30. Сравнить результаты Decision Tree и Random Forest на одном и том же разбиении для каждого вложения.

Методическое ограничение: t-SNE в стандартной реализации scikit-learn не предоставляет обычный метод transform для новых объектов. Если вложение строится сразу по всему набору, а затем координаты делятся на train/test, тестовые объекты уже участвовали в построении карты. Такие оценки следует обозначить как исследовательское сравнение классификации в полученном 2D-пространстве, а не как независимую оценку полного конвейера для новых данных. Для строгой оценки обобщения используйте методы с поддержкой transform либо отдельно опишите выбранную стратегию для t-SNE.

Этап 6. Сравнительный анализ

Составить итоговую таблицу по всем методам, включив размерность, использованные параметры, показатели визуальной/структурной сохранности, результаты кластеризации и метрики классификаторов. Определить, какое вложение лучше подходит для визуального анализа, какое обеспечивает более согласованную с исходными классами кластерную структуру и на каком представлении классификаторы работают лучше.

Необходимо отдельно отметить, что хорошее визуальное разделение не гарантирует высокой точности классификатора, а высокая точность на двумерном вложении не доказывает, что исходные данные имеют простую геометрическую структуру.

6. Требования к результатам

Результат	Минимальное требование
Исходные данные	Не менее 6 непрерывных признаков; описание числа объектов и классов.
Вложения	5 методов × 2 размерности = 10 визуализаций (2D и 3D).
Подбор параметров	Не менее 2 конфигураций для каждого метода либо обоснование выбранной конфигурации.
K-means	Для каждого вложения K = 3, 4, 5, 6; таблицы долей исходных классов в кластерах.
Классификация	Для каждого 2D-вложения: Decision Tree и Random Forest.
Границы решений	10 визуализаций границ решений: 5 вложений × 2 классификатора.
Метрики	Accuracy, Precision, Recall, F1-score, матрица ошибок; для кластеризации — Silhouette и ARI/NMI при возможности.
Воспроизводимость	Код, параметры, random_state, версии библиотек и сохранённые графики.

7. Содержание отчёта (презентации)

1. Титульный лист: ФИО, группа, номер варианта, название работы.
2. Цель и задачи лабораторной работы.
3. Описание набора данных: источник, число объектов, классы, выбранные непрерывные признаки, описательная статистика и баланс классов.
4. Описание предварительной обработки: пропуски, выбросы, стандартизация, подвыборка (если использовалась).
5. Таблица параметров MDS, Isomap, LLE, t-SNE и UMAP.
6. Двумерные и трёхмерные визуализации всех пяти методов с цветовой маркировкой исходных классов.
7. Сравнительный анализ вложений и, при наличии, показатели trustworthiness и stress.
8. Результаты K-means для K = 3, 4, 5 и 6: таблицы состава кластеров, диаграммы и метрики качества кластеризации.
9. Параметры Decision Tree и Random Forest для каждого двумерного вложения.
10. Графики границ решений, матрицы ошибок и сравнительные таблицы метрик классификации.
11. Обсуждение ограничений эксперимента, в том числе особенностей t-SNE и возможной утечки информации при построении вложения.
12. Программный код с комментариями и выводы.

8. Контрольные вопросы

1. Что такое снижение размерности и для решения каких задач оно применяется?
2. Что понимается под многообразием в контексте анализа данных?
3. Почему перед методами, основанными на расстояниях, часто требуется стандартизация признаков?
4. В чём заключается идея многомерного шкалирования MDS?
5. Как метод Isomap оценивает геодезические расстояния?
6. Какой принцип лежит в основе Locally Linear Embedding (LLE)?
7. Какие задачи решает t-SNE и почему он особенно часто используется для визуализации?
8. Что такое perplexity в t-SNE и как её выбор влияет на результат?
9. Как работает UMAP и какую роль играет параметр n_neighbors?
10. Почему результаты разных запусков методов снижения размерности могут отличаться?
11. Почему расстояния между удалёнными группами на t-SNE-карте нельзя трактовать как точные расстояния в исходном пространстве?
12. В чём отличие кластеризации K-means от классификации?
13. Почему метки классов не должны использоваться при обучении K-means в данном эксперименте?
14. Что показывают Silhouette Score, ARI и NMI?
15. Как строятся границы решений дерева решений и случайного леса в двумерном пространстве?
16. Почему дерево решений может переобучаться и как ограничить его сложность?
17. В чём преимущества Random Forest по сравнению с одним деревом решений?
18. Почему хорошая визуализация не обязательно означает высокое качество классификации?
19. Что такое утечка данных при построении вложения и как её избежать?
20. Какие ограничения возникают при применении t-SNE к новым объектам?

9. Критерии оценивания

Компонент	**Баллы**
Подготовка и описание набора данных, выбор признаков	10
Корректная реализация пяти методов в 2D и 3D	25
Анализ параметров и интерпретация визуализаций	10
K-means для K = 3–6, состав кластеров и метрики	20
Decision Tree и Random Forest, границы решений и метрики	20
Сравнительный анализ, выводы, качество отчёта и кода	15
Итого	100

10. Ожидаемые результаты

По итогам лабораторной работы студент должен продемонстрировать умение применять методы MDS, Isomap, LLE, t-SNE и UMAP для отображения многомерных данных в 2D и 3D; анализировать полученные структуры; выполнять кластеризацию без использования истинных меток; строить классификаторы на двумерных вложениях и корректно интерпретировать метрики. Численные результаты заранее не задаются и должны быть получены в ходе экспериментов.